# Inferência Bayesiana para a Probabilidade de Cancelamento de Clientes em uma Empresa de Telecomunicações

Amanda Rehder Cerdo – RA: 253507
Pedro Galhardo Barbosa – RA: 277218

## Resumo do problema

A retenção de clientes é um dos principais desafios das empresas de telecomunicações, uma vez que o cancelamento de serviços (churn) impacta diretamente a receita e os custos de aquisição de novos consumidores. Neste trabalho, utiliza-se o conjunto de dados IBM Telco Customer Churn, contendo informações de 7043 clientes, incluindo características demográficas, serviços contratados, tipo de contrato, tempo de permanência e indicador de cancelamento.

O objetivo é estimar, sob uma perspectiva Bayesiana, a probabilidade de um cliente cancelar o serviço da empresa, avaliando a sensibilidade da distribuição a posteriori frente a diferentes escolhas de distribuições a priori, tendo em vista que conhecer a probabilidade de cancelamento permite que estratégias de retenção sejam planejadas de forma mais eficiente.

## Metodologia

Para a formulação matemática do problema, considera-se a variável indicadora binária $Y_i$ associada ao $i$-ésimo cliente, definida por:

$$Y_i = \begin{cases} 1, & \text{se o cliente cancelou o serviço,} \\ 0, & \text{caso contrário.} \end{cases}$$

Assume-se que as observações da amostra são independentes e identicamente distribuídas (i.i.d.) segundo uma distribuição Bernoulli com parâmetro $\theta$: $Y_1, \ldots, Y_n \overset{\text{iid}}{\sim} \text{Bernoulli}(\theta)$, em que $\theta \in (0,1)$ representa a probabilidade populacional de *churn* e constitui o parâmetro de interesse dentro do espaço paramétrico $\Theta = (0,1)$.

Com base nos componentes do modelo, a função de verossimilhança para $\theta$ é dada por: $L(\theta \mid y) = \prod_{i=1}^{n} \theta^{y_i}(1-\theta)^{1-y_i} = \theta^s(1-\theta)^{n-s}$, onde $s = \sum_{i=1}^{n} y_i$ representa o número total de clientes que cancelaram o serviço.

Como não há conhecimento prévio forte sobre a taxa de cancelamento dos clientes, foi adotada uma distribuição Beta uniforme para o parâmetro de interesse: $\theta \sim \mathbf{Beta}(a, b)$, com $a = b = 1$.

Dessa forma, $\pi(\theta) = 1$, $0 < \theta < 1$, representando uma distribuição não informativa, na qual todos os valores possíveis para a probabilidade de churn possuem a mesma plausibilidade inicial.

A escolha da distribuição Beta é conveniente devido ao seu suporte coincidir com o espaço paramétrico do problema, isto é, o intervalo $(0,1)$, além de ser amplamente utilizada em modelos para proporções e probabilidades.

Mesmo havendo forma analítica fechada para a posteriori, simularam-se amostras por meio do algoritmo Metropolis-Hastings. A partir de um valor inicial $\theta^{(0)}$, propõe-se uma cadeia baseada em uma distribuição de caminhada aleatória com suporte em uma distribuição Normal centralizada no estado anterior: $\theta^* \sim q(\cdot \mid \theta^{(t-1)}) \equiv N(\theta^{(t-1)}, \sigma^2)$, definindo-se fixamente o desvio padrão como $\sigma = 0{,}03$. Caso a proposta $\theta^*$ resulte em um valor externo ao intervalo $(0,1)$, ela é automaticamente rejeitada por inconsistência com o espaço paramétrico. A cada passo $t$, aceita-se o candidato com probabilidade dada pela razão de aceitação:

$$\alpha = \min\left\{1,\ \frac{\pi(\theta^* \mid y)}{\pi(\theta^{(t-1)} \mid y)}\right\}.$$

O procedimento prático de execução do algoritmo MCMC estruturou-se sob as seguintes etapas sequenciais:

1. Escolher um valor inicial adequado para $\theta^{(0)}$.
2. Para cada iteração $t = 1, \ldots, M$, gerar o candidato $\theta^* \sim N(\theta^{(t-1)}, \sigma^2)$.
3. Se $\theta^* \notin (0,1)$, definir $\theta^{(t)} = \theta^{(t-1)}$; caso contrário, prosseguir.
4. Calcular a razão $\alpha$ a partir das densidades da posteriori avaliadas nos pontos correspondentes.
5. Sorteia-se uma variável auxiliar uniforme $u \sim U(0,1)$.
6. Se $u < \alpha$, aceita-se a proposta definindo $\theta^{(t)} = \theta^*$; caso contrário, mantém-se $\theta^{(t)} = \theta^{(t-1)}$.
7. Repetir os passos até que o total planejado de $M = 20.000$ iterações seja atingido.

Para mitigar a influência das condições iniciais e garantir o estado estacionário da cadeia, as primeiras 5.000 observações geradas foram integralmente descartadas a título de período de *burn-in*. As amostras remanescentes serão utilizadas para estimar a média a posteriori, construir os intervalos de credibilidade estritos e conduzir as análises preditivas do problema de negócios.